



이미지 복원

CCTV 어두운 이미지를 중심으로



[RestoreNet]

목차

A table of contents

1 배경

2 데이터

3 모델

4 성능

5 서비스



1

배경

배경 소개 및 활용 방안

1 배경

1.1 배경 소개



Deblur

Blur를 제거하는 과정에서
이미지의 Edge를 강화하여
Noise가 더 잘 보이게 됨




Denoise

Noise를 제거하는 과정에서
이미지의 Edge를 약화시켜 Blur처
럼 보이게 됨

1 배경

1.2 도전 과제



1 배경

1.3 연구 목적

목적: Deblur와 Denoise를 한 번에 처리할 수 있는 Model을 만들자!
trade-off 관계인 Deblur와 Denoise




1 배경

1.3 연구 목적 및 활용



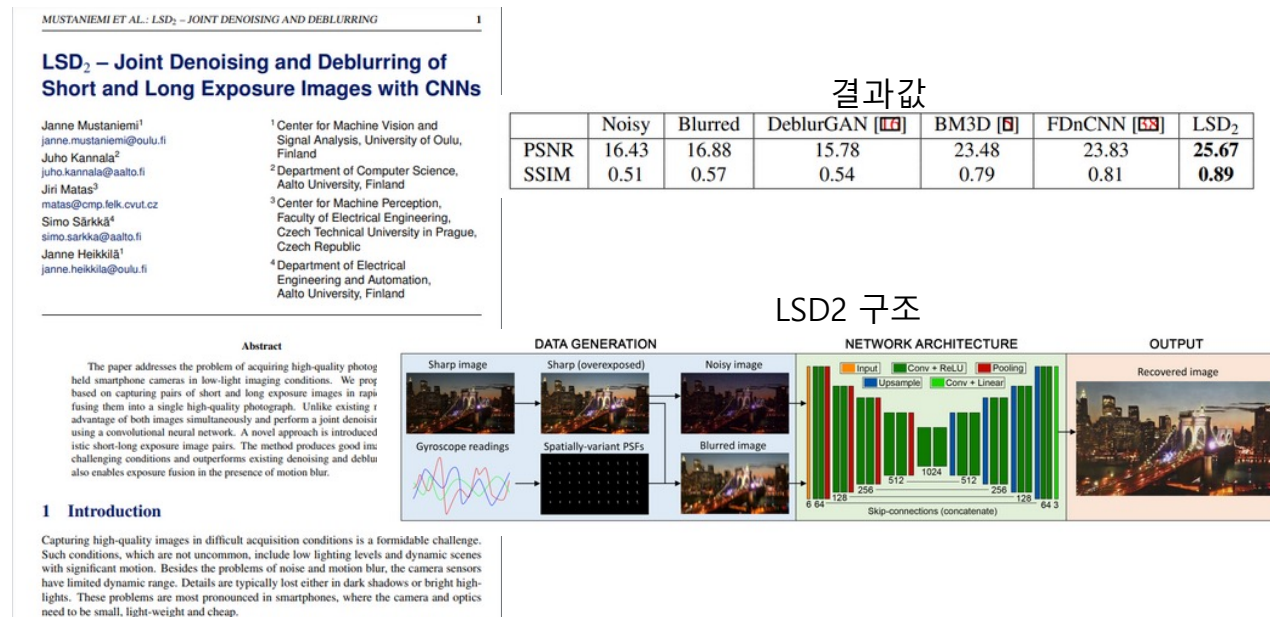
활용: 어두운 환경의 CCTV 이미지를 복원

어두운 환경은 느린 셔터스피드로 인해 Blur, ISO값이 높아 노이즈가 생기기 쉽고,
CCTV는 스마트폰이나 카메라에 비해 이미지 센서 등의 성능이 낮아 노이즈가 생기기 쉬움



1 배경

1.4 기존 Model: LSD2



카메라 조리개 노출 속도를 짧고 길게 찍은 두 Image를 Input에 삽입,
U-Net 구조를 거쳐 Output 획득

1 배경

1.5 기존 Model과 우리 모델 비교

Input



LSD2



RestoreNet(Ours)



Ground Truth



Ours와 LSD2 비교

LSD2에 비하여 RestoreNet(Ours)이 Noise와 Blur를 더 잘 처리하는 것을 확인

데이터

데이터 소개 및 전처리



2

2 데이터

2.1 학습에 필요한 Dataset 종류

GT
Ground Truth


Blur Image

Noise Image

Noise + Blur
Image

2 데이터

2.2 데이터 Augmentation 기법



2 데이터

2.3 수집 Dataset 목록



RealBlur

Real-world blur dataset acquired from wide-angle lens



RealBlur-Tele

Real-world blur dataset acquired from telephoto lens



BSD-B

Synthetic uniform blur dataset using BSD dataset



GoPro Large

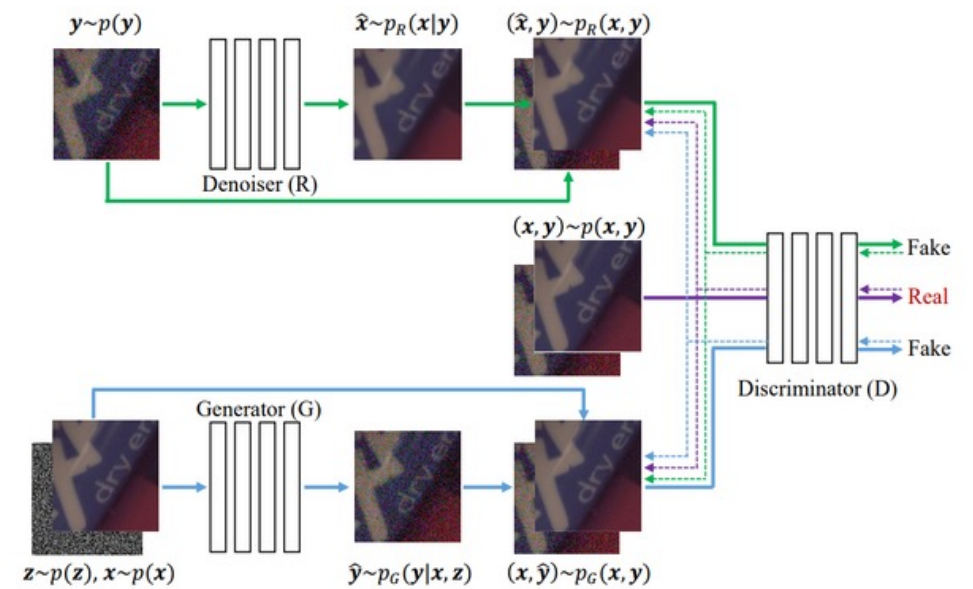
Blurry and sharp image pairs. Blurry images includes both gamma corrected and not corrected (linear CRF) versions.

2 데이터


2.4 데이터 전처리 기법 선정

DANet을 사용하여 이미지에 Noise를 생성

*DANet : SIDD를 통하여 학습한 noise generation model



Input



Output



어두운 CCTV 데이터에 잘 대응하기 위해 어두운 사진을 데이터셋으로 활용
그러나 아래와 같이 Blur가 남아있는 문제 있음


2 데이터

2.5 데이터 전처리 과정

명도가 낮은 데이터셋



SV 분석 결과



Real_blur Dataset의 SV 분석 결과 **V(명도)**가 낮은 Data들이 다수 존재
명도가 낮은 이미지를 선정 후 **학습 데이터셋**에서 제외한 뒤 훈련 재개

Input



output



학습 데이터셋에 명도가 0.2 이하인 데이터를 제외
어두운 이미지를 Test Set으로 Validation 해봤을 때 Deblur가 잘 되는 것을 확인



3


모델

모델 소개 및 전략

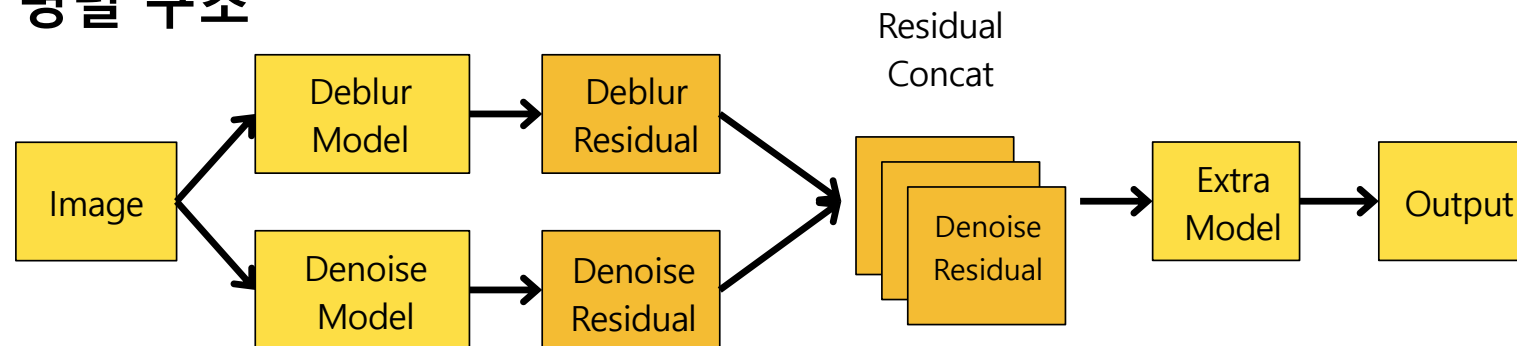
3 모델

3.1 모델 개요

직렬 구조 (대조용)




병렬 구조




3 모델

3.1 모델 개요

직렬 구조 (대조용)




병렬 구조



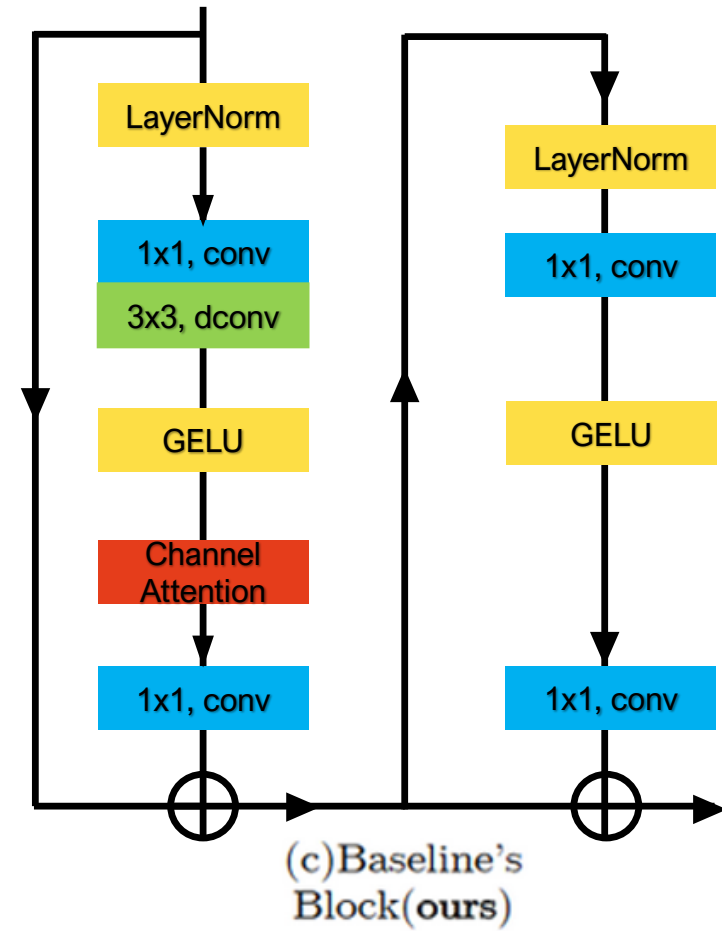
3 모델

3.2 공통 Backbone: Baseline-width64



(c) UNet Architecture(ours)

Simple Baselines for Image Restoration의
Baseline 모델 사용



(c) Baseline's
Block(ours)

3 모델

3.2.1 Deblur Backbone: Gopro-Baseline-width64



| GoPro Dataset으로 훈련한 Baseline을 사용

GoPro Dataset:

1280x720 크기의 3214개의 Blur된 사진과 고속 카메라로
찍은 Ground-Truth 사진

3 모델

3.2.2 Denoise Backbone: SIDD-Baseline-width64



| SIDD Dataset으로 훈련한 Baseline을 사용

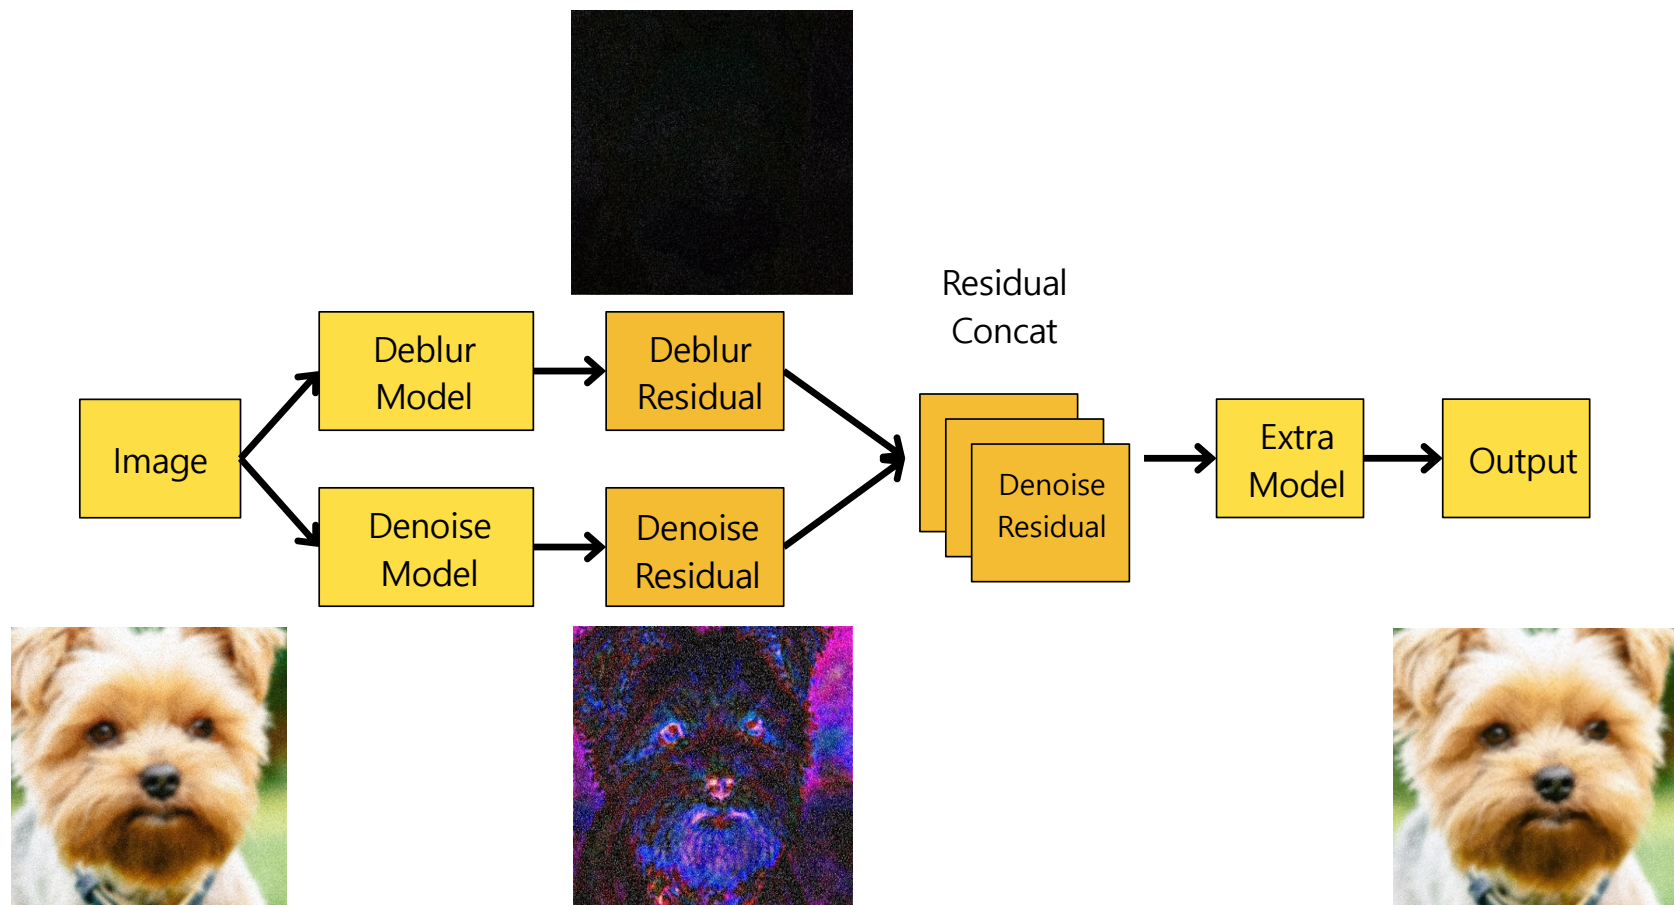
SIDD Dataset:

10개의 Scene, 5종류의 스마트폰 카메라에서 촬영한 30000개의

Noise가 있는 이미지 및 Ground Truth 이미지

3 모델

3.3 병렬 구조



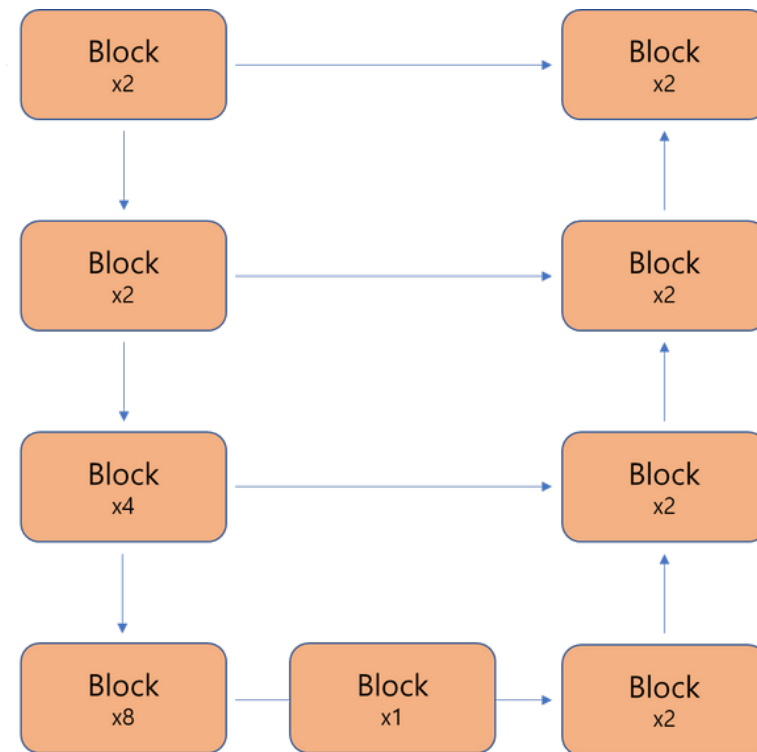
3 모델

3.4. Extra Model 선정

- 1) Conv+Deconv
- 2) U-Net
- 3) Baseline(Width16)
- 4) Baseline(Width16)+Conv
- 5) Baseline(Width32)
- 6) Baseline(Width64)

* Width = 첫 Block에 들어가는
Channel의 수

총 4개의 level로 이루어진 U-Net 구조
Encoder 부분: 2, 2, 4, 8 개의 Baseline Block
Decoder 부분: 2, 2, 2, 2 개의 Baseline Block

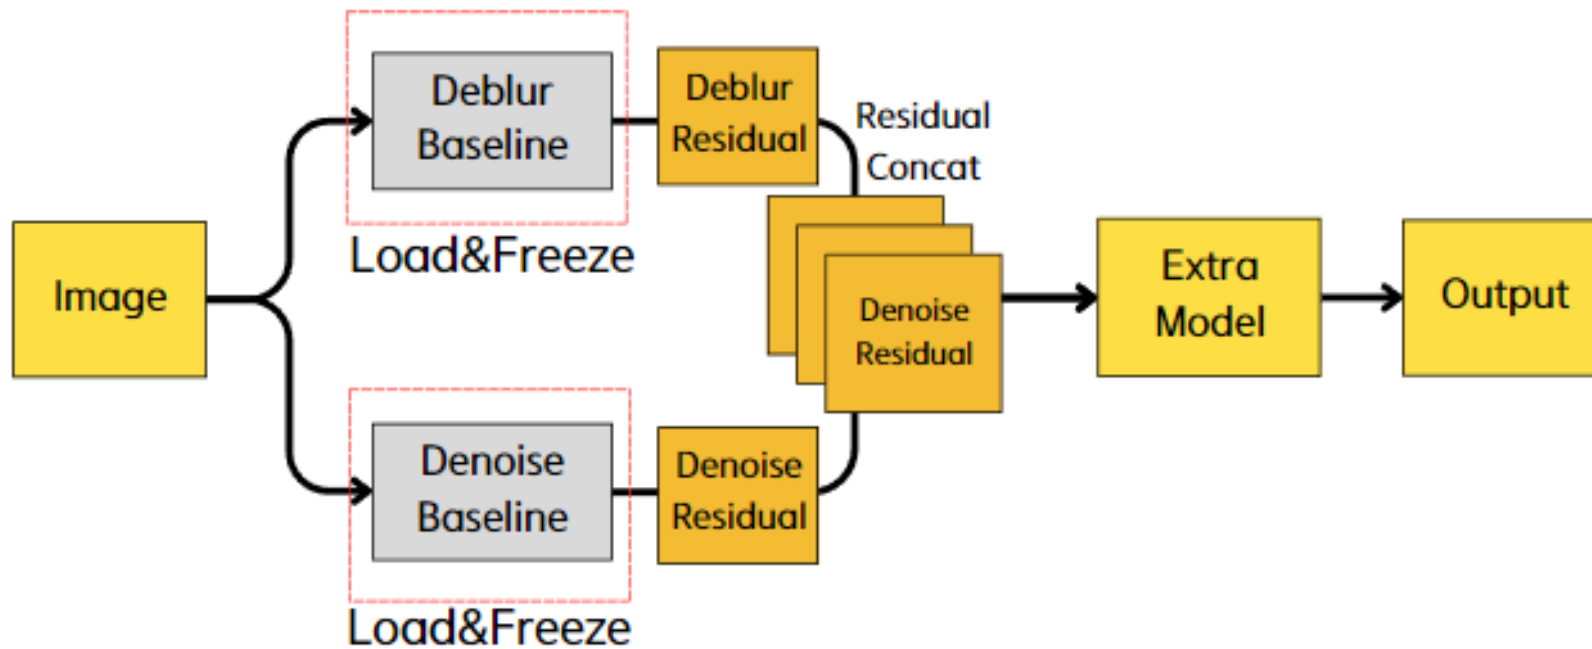


3 모델

3.5 학습 전략 소개

Load & Freeze

Pretrained Deblur, Denoise model을 불러오고 Freeze

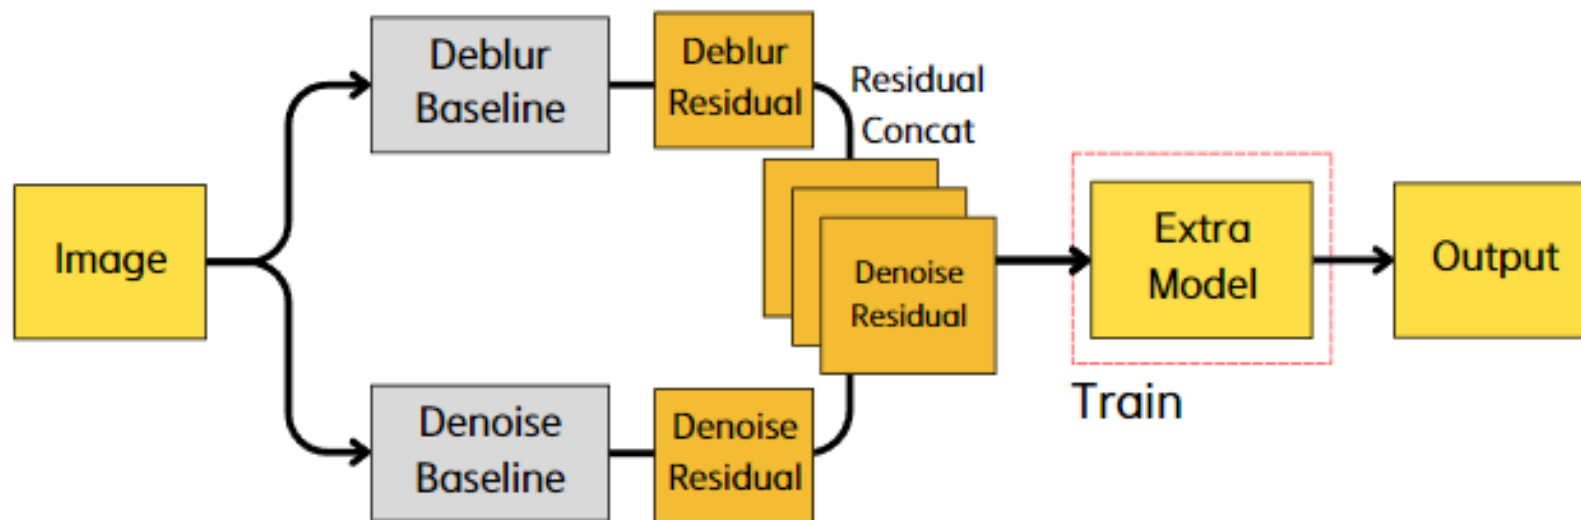


3 모델

3.5 학습 전략 소개

Train

Deblur, Denoise model의 Pretrained weight를 반영 후 Extra Model 학습

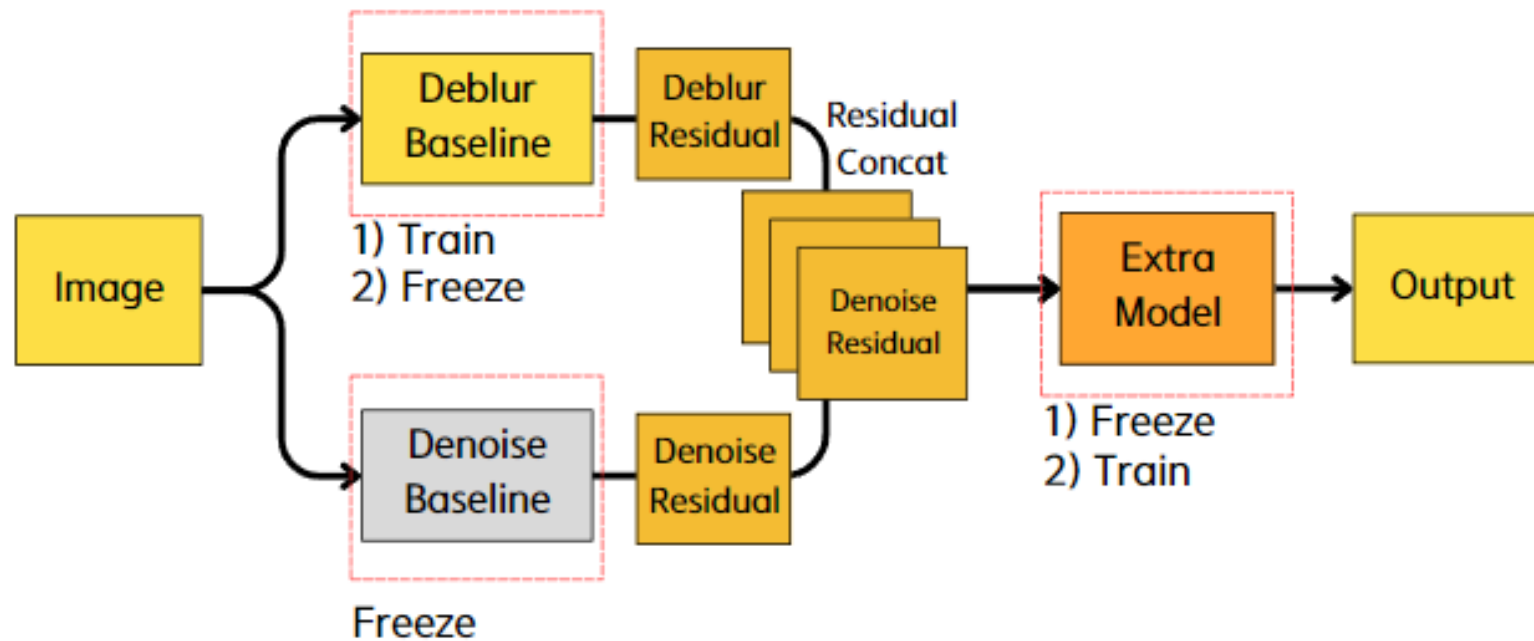


3 모델

3.6 추가 학습 전략 소개

Alternative Train

- 1) Extra Model을 freeze하고 Deblur Model 추가 학습
- 2) Deblur Model freeze 후 Extra Model 학습



3 모델

3.7 학습 데이터셋 구성

Strategy 1

Data Set 별로
일정 비율 추출

Blur+Noise : Blur : Noise : GT

13 : 2 : 2 : 1

11 : 4 : 4 : 1

8 : 4 : 4 : 1

Strategy 2

Blur+Noise만 사용

Blur+Noise : Blur : Noise : GT

1 : 0 : 0 : 0

Strategy 3

특정 Data Set만 사용

BSD

성능

성능 지표 소개 및 결과

4

4 성능

4.1 성능 지표 소개

PSNR (Peak Signal-to-Noise Ratio)

최대 신호와 잡음의 비율로 품질을 측정

$$PSNR = 10 \log_{10} \left(\frac{R^2}{MSE} \right)$$

SSIM (Structural SIMilarity)


원본 영상과 손실 영상의 휘도, 명암, 구조 정보를 비교하여 계산

$$SSIM(x, y) = \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)}$$

4 성능


4.2 PSNR과 SSIM

PSNR



Width-64
Width-32

SSIM



Width가 64인 모델이 32인 모델에 비해 높은 PSNR을 보여주었다.


4 성능

4.2 PSNR과 SSIM

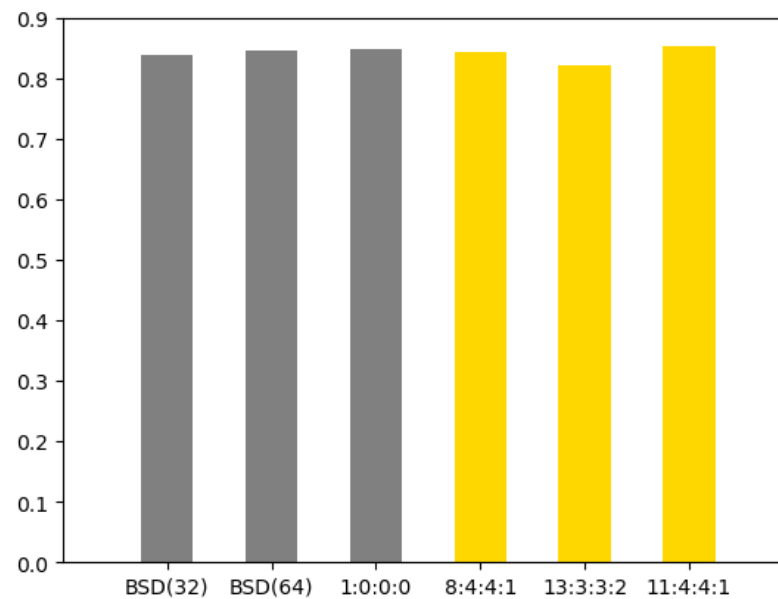
Input Data Set Ratio

Blur+Noise : Blur : Noise : GroundTruth

PSNR




SSIM



특정 Data Set(BSD) 또는 [Blur + Noise] Data Set로만 학습시킨 모델보다 여러 비율로 구성된 데이터셋으로 학습한 모델의 성능이 좋음

4 성능

4.2 PSNR과 SSIM



Blur+Noise : Blur : Noise : GroundTruth

BSD(64)	11 : 4 : 4 : 1
BSD(32)	13 : 3 : 3 : 2
1 : 0 : 0 : 0	8 : 4 : 4 : 1

하지만 데이터 비율을 나눠 학습한 모델은 loss의 변화폭이 넓고 학습시킨 iter 수가 부족

Loss의 변화폭이 적고 학습 수도 적당한 BSD(64) 모델을 선정



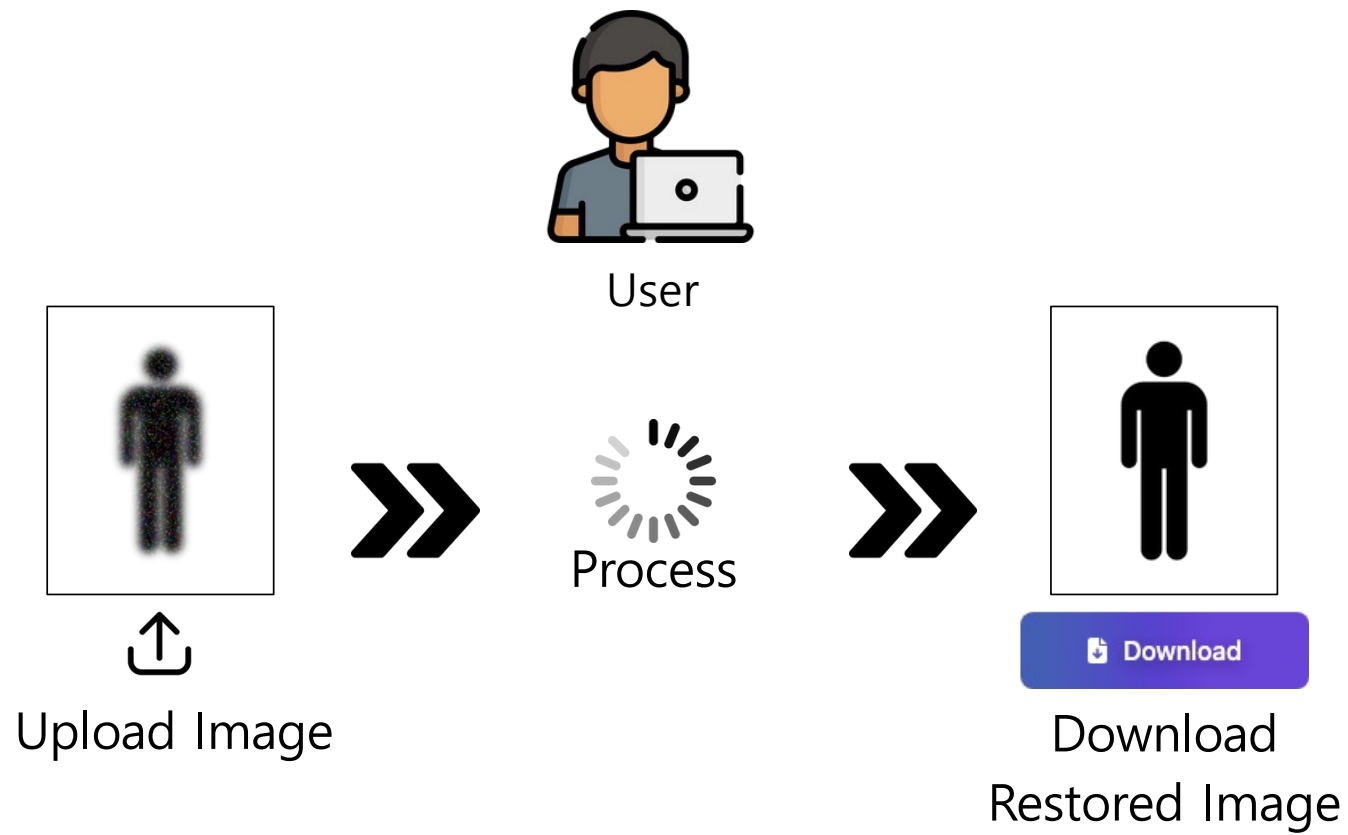
5

서비스

서비스 소개 및 예시

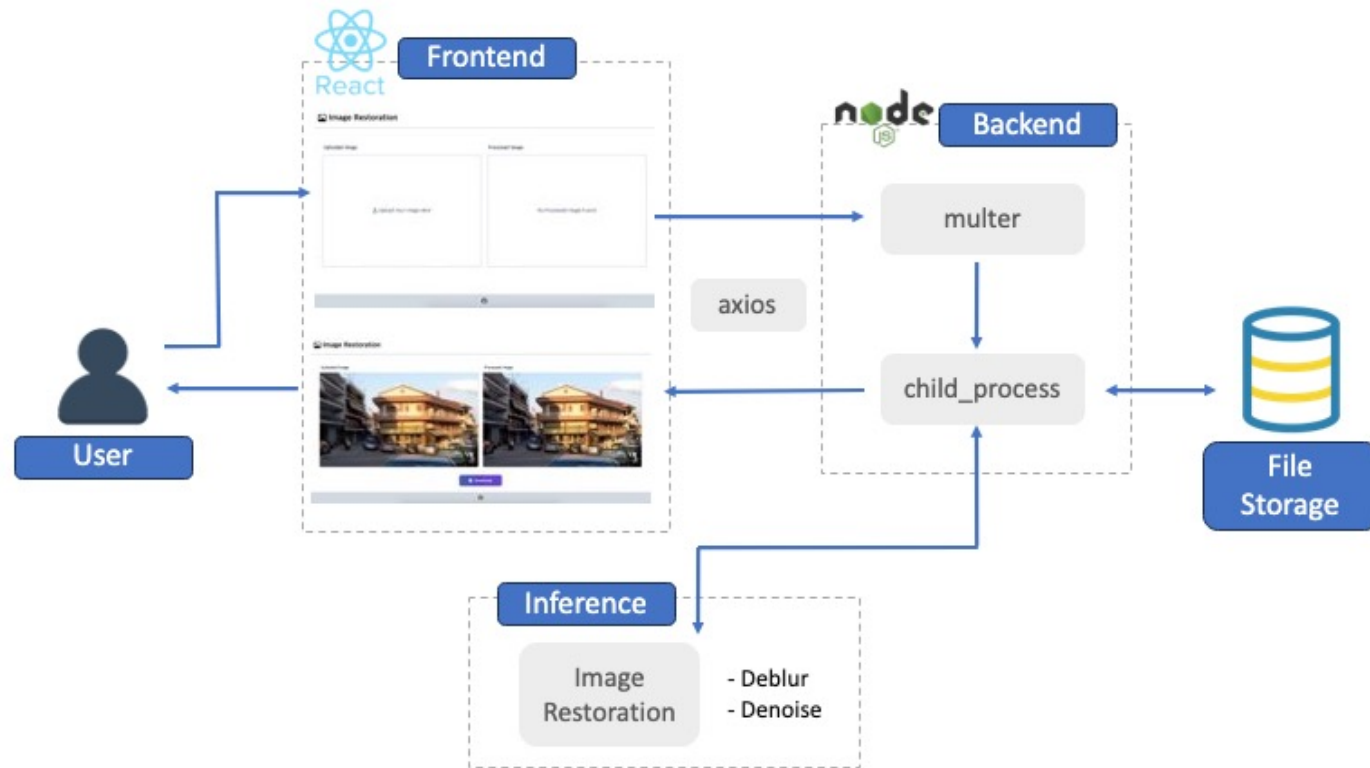
5 서비스

5.1 서비스 개요



5 서비스

5.2 서비스 플로우




웹 프론트엔드로 React를 사용하여 유저에게 인터페이스 제공
백엔드로 Express를 사용하여 React와 Model을 API로 연결

5 서비스


5.3 서비스 예시

Image Restoration

Uploaded Image



Processed Image



| 웹 사이트에 이미지를 업로드

5 서비스

5.3 서비스 예시


Image Restoration

Uploaded Image



Processed Image



 Download



| 업로드 한 이미지와 처리가 완료된 이미지를 확인

6 참고 문헌

- [1] L. Chen, X. Chu, X. Zhang, and J. Sun, "Simple baselines for image restoration," *2022 ECCV : 17th European Conference*, pp. 17–33, 2022. doi:10.1007/978-3-031-20071-7_2
- [2] S. W. Zamir et al., "Multi-Stage Progressive Image Restoration," *2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2021. doi:10.1109/cvpr46437.2021.01458
- [3] L. Chen, X. Lu, J. Zhang, X. Chu, and C. Chen, "HINet: Half instance normalization network for image restoration," *2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*, 2021. doi:10.1109/cvprw53098.2021.00027
- [4] J. Liang et al., "Swinir: Image restoration using swin transformer," *2021 IEEE/CVF International Conference on Computer Vision Workshops (ICCVW)*, 2021. doi:10.1109/iccvw54120.2021.00210
- [5] S. W. Zamir et al., "Restormer: Efficient Transformer for high-resolution image restoration," *2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2022. doi:10.1109/cvpr52688.2022.00564

6 참고 문헌

- [6] J. Rim, H. Lee, J. Won, and S. Cho, "Real-world blur dataset for learning and benchmarking Deblurring algorithms," *Computer Vision – ECCV 2020*, pp. 184–201, 2020. doi:10.1007/978-3-030-58595-2_12
- [7] Y. Zhao et al., "D2HNet: Joint denoising and Deblurring with hierarchical network for robust night image restoration," *2022 ECCV : 17th European Conference*, pp. 91–110, 2022. doi:10.1007/978-3-031-20071-7_6
- [8] D. Sun, Y. Shi, and Y. Feng, "Blind deblurring and denoising via a learning deep CNN denoiser prior and an adaptive L0-regularised gradient prior for passive millimetre-wave images," *IET Image Processing*, vol. 14, no. 17, pp. 4774–4784, 2020. doi:10.1049/iet-ipr.2020.1193
- [9] Y. Pang, J. Lin, T. Qin, and Z. Chen, "Image-to-image translation: Methods and applications," *IEEE Transactions on Multimedia*, vol. 24, pp. 3859–3881, 2022. doi:10.1109/tmm.2021.3109419
- [10] J. Su, B. Xu, and H. Yin, "A survey of deep learning approaches to image restoration," *Neurocomputing*, vol. 487, pp. 46–65, 2022. doi:10.1016/j.neucom.2022.02.046

6 참고 문헌

- [11] J. Mustaniemi, J. Kannala, J. Matas, S.Särkkä, and J. Heikkilä, "LSD2 — Joint Denoising and Deblurring of Short and Long Exposure Images with CNNs, The 31st British Machine Vision Virtual Conference(BMVC), 2020.
- [12] Y. Park, M. Jeon, J. Lee, and M. Kang, "MCW-net: Single Image deraining with multi-level connections and wide regional non-local blocks," *Signal Processing: Image Communication*, vol. 105, p. 116701, 2022. doi:10.1016/j.image.2022.116701
- [13] S. Xie, R. Girshick, P. Dollar, Z. Tu, and K. He, "Aggregated residual transformations for deep neural networks," *2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017. doi:10.1109/cvpr.2017.634
- [14] S. Ioffe, and C. Szegedy, "Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift", *ICML'15: Proceedings of the 32nd International Conference on International Conference on Machine Learning*, vol.37, pp.448-456, 2015. doi:10.48550

감사합니다